

初赛方案 · 方向三：材料科学文献驱动的科学发现智能体

主题一：硫化物固态电解质（argyrodite $\text{Li}_6\text{PS}_5\text{Cl}$ ）的合成路线与工艺优化

项目	内容
赛道	赛道三：前沿探索 AI for Research
题目类型	题目类型一 · 算法赛题
方向	方向三：材料科学文献驱动的科学发现智能体
进阶路线	路线 C：合成路线与工艺设计
提交阶段	初赛
文档用途	按《初赛提交模板》四段结构详写的初赛方案，兼作算法赛题要求的"方案说明文档 / 技术路线概述"
撰写日期	2026-08-02
初步验证	☒ 最小试跑闭环已跑通（2026-08-02，详见 §4.4）

说明：本方案依据根目录《世界人工智能大赛.md》（赛题文档）与《初赛提交模板.md》（模板）撰写。模板原为开放探索赛的"问题定义文档"框架，此处借用其"问题与证据 → 环境接口 → 发现信号与参照 → 最小验证计划"四段结构，完整交代本主题的问题定义、Agent 探索环境、发现信号与验证计划。

一、问题与证据

1.1 真实问题或需求

情境与对象：下一代锂离子电池需要更高的能量密度与更好的安全性，用固态电解质替代液态电解液是关键路径。主流无机固体电解质分成两大体系：

- **硫化物**（如硫银锗矿型 $\text{Li}_6\text{PS}_5\text{Cl}$ 、 Li_3PS_4 、LGPS）：室温离子电导率高（ $10^{-3}\sim 10^{-2}\text{ S/cm}$ ，可接近甚至超过液态电解液），但对空气与水分极敏感，遇水产生有毒 H_2S 气体，加工须在惰性气氛下进行，成本高、规模化难。
- **氧化物**（如石榴石型 LLZO、NASICON 型 LATP）：化学稳定性好、对空气稳定，但离子电导率偏低，且烧结温度常需 $>1000^\circ\text{C}$ ，界面阻抗大。

科研界与工业界共同的真实困扰是：“**高离子电导率 + 空气/水分稳定性 + 低温可规模化合成**”三者难以兼得。硫化物方向尤其需要找到掺杂/卤素混配与合成工艺的联合优化方案，在电导率、稳定性、成本之间取得平衡。

具体困扰：以文献量最大、Gap 最清晰的 **argyrodite 型 $\text{Li}_6\text{PS}_5\text{Cl}$** 为例——卤素混配（Cl/Br/I）、元素掺杂、球磨与退火工艺的组合空间巨大，相关合成论文上千篇，条件与性能的关联散落在论文正文与补充材料中，人工阅读无法穷举“掺杂 $\times$ 工艺”的联合优化空间，更无法系统回答“哪个组合能同时改善空气稳定性与电导率”。

1.2 为什么尚未被结构化

1. **无统一标准化数据库：**电导率、活化能、稳定性、相纯度等性能没有统一的字段与规范，数据大量以非结构化文本形式存在于论文正文、表格与补充材料中。
2. **测量条件不可直接比较：**阻抗谱测试温度、压片致密度、烧结气氛、测试夹具等条件各异，同一配方在不同实验室得到的结果往往无法直接对比。
3. **文献结论互相矛盾：**例如 Cl:Br 混配比例、金属掺杂元素对电导率与稳定性影响的结论在不同报道中并不一致，人工难以判断哪些是真实信号、哪些是测量差异或样本差异。
4. **现有综述覆盖单一维度：**已有综述多聚焦“电导率”或“稳定性”单一方面，缺少“掺杂 $\times$ 工艺 $\times$ 性能”联合视角的系统化挖掘，尤其缺乏对“尚未被联合验证的组合”的定位。

1.3 研究价值与合适切片

研究价值：固态电解质是"AI 预测 → 湿实验验证"科研闭环中极具产业意义的领域。构建一个从文献出发、产出**可证伪的合成路线假设**的智能体，既能直接为实验团队提供候选配方与工艺，也推动材料领域知识生产自动化，可沉淀为社区可复用的智能体范式。

合适切片（避免"解决固态电池"这类终极问题）：聚焦 **argyrodite 型 $\text{Li}_6\text{PS}_5\text{Cl}$ 的卤素混配 + 元素掺杂 + 球磨/退火工艺的联合优化**，目标是在这一明确体系内找到"尚未被联合报道但各步骤均有文献支撑"的掺杂-工艺组合，并输出带证据链的合成路线建议。

AI 能提供的能力（对应文档要求）：

- **观察/检索：**Sciverse 语义检索覆盖 2500 万+文献，支持全文定位，可大规模扫描材料合成文献；
- **生成：**LLM 生成候选掺杂组合、合成路线假设与结构化调研报告；
- **归纳：**把非结构化文献抽取为"配方-工艺-性能"结构化记录，识别矛盾与 Gap；
- **搜索/验证：**贝叶斯优化/遗传算法等搜索空间探索 + Materials Project / 热力学代理检查交叉验证。

二、环境接口

2.1 固定规则

- **文献空间：**Sciverse 科学智能数据库（材料学科范围），辅以 Sci-Base（Hugging Face）与 MinerU（PDF 解析）；
- **化学约束：**元素价态与电中性、argyrodite 结构类型（空间群 F-43m）与相稳定性、合成温度上限（ $\leq 700^\circ\text{C}$ ）、惰性气氛要求、安全约束（硫化物遇水产 H_2S ）；
- **证据规则：**任何性能断言必须绑定可回溯的文献 ID；区分"实验验证"与"理论/推测"两类证据等级；
- **评价口径：**离子电导率（ σ ）、活化能（ E_a ）、空气稳定性（ H_2S 产生量/颜色变化）、相纯度、烧结温度，五类指标固定；
- **预算：**单轮检索调用次数上限、候选路线数量上限（初版固定）。

2.2 观察 / 行动 / 反馈

Agent 可观察到的信息：

- 检索命中的文献元数据与摘要；
- 从文献中抽取出的结构化记录（配方、工艺、性能、来源等级）；
- 知识库的统计分布（各元素/工艺出现频次、性能分布）；
- 已有的 Gap 清单与候选假设列表。

Agent 可执行的动作：

1. 构造/改写检索查询（组合体系名 × 掺杂 × 工艺 × 性能关键词）；
2. 筛选文献（纳入/排除，标注理由）；
3. 抽取字段（组成、前驱体、球磨时长、退火温度/时间、气氛、性能值）；
4. 提出假设（候选掺杂组合与工艺窗口）；
5. 生成合成路线（前驱体选择、步骤顺序、反应条件）；
6. 发起验证（Materials Project 结构查询、热力学可行性代理计算、矛盾检测）。

每个动作后得到的反馈：

- 证据链强度评分（每条建议关联的文献数量与证据等级）；
- 结构新颖性（候选组合与已有记录的相似度/距离）；
- 可行性检查通过/失败（数据库、相图、热力学代理）；
- 矛盾命中（同一条件下不同文献结论相反的数量）；
- LLM 自洽性评分（假设与检索证据的一致性）。

2.3 记录与预算

- **状态保存：**结构化知识库（每条记录含 文献ID、配方、工艺、性能、证据等级）、假设库、候选路线库；
- **日志：**检索查询 + 时间戳 + 命中数、抽取变更记录、每步生成/验证的中间结果——天然构成可审计的证据链；
- **预算：**检索调用数、token 消耗、API 费用（Sciverse / Materials Project / LLM）三类资源分别计数。

2.4 系统架构与技术选型

本方案的系统是一个**自研的文献科学发现流水线**，采用两层架构：**数据/审计层**为纯 Python 标准库代码（agent/，零第三方依赖），**编排层**（discover 阶段）基于开源框架 **AgentScope 2.0**（Apache-2.0，唯一运行时框架依赖，见 requirements.txt）构建自主发现循环。对比过的 LangGraph / Pydantic AI / 专用 Agent 改造均不采用（理由见开发报告）。Claude 仅作为开发期的辅助工具参与本项目构建，不属于交付系统，也不在运行时被调用。

运行时技术栈（当前已实现）

层	技术选型	说明
编排与调度	自研 agent/run.py 流水线（数据/审计层 纯标准库： urllib.request / json / threading）	smoke-llm / search / screen / content / extract / validate / evaluate / gen / compare / discover / full 各阶段可独立重跑
认知层编排 (discover)	AgentScope 2.0 Agent + FunctionTool（十阶 段函数薄封装为 10 个 工具）	「读知识库 → Gap → 补检 → 假设/路线 → 写回 JSONL」 自主循环；事件流全量落审 计日志；写工具强制证据锚 点、id 续编
文献检索	Sciverse REST （/agentic-search 语义检索）	查询词表驱动，命中增量合 并 hit_catalog，调用记录 构成可审计证据链
全文获取	Sciverse 全文 JSON	按 doc_id 存档，供抽取与 回溯
LLM 推理	Anthropic 兼容端点 （DeepSeek deepseek-v4-flash， 已禁用 thinking）	仅用于结构化抽取与基线路 线生成，固定 JSON schema
交叉验证	Materials Project REST	仅结构/热力学背景，不验证 合成路线

层	技术选型	说明
存储	JSON/JSONL 追加式 知识库 + 日志	data/01_literature ~ data/99_logs 六段目录
证据锚点	doc_id → record_id → 原始全文 JSON	每条科学主张可回溯

六层能力视图与实现状态

检索层（已实现）→ 筛选层（已实现）→ 抽取层（已实现）→ **认知层（Gap 识别 / 假设生成 / 路线策划）** → 验证层（MP 背景 + 原文审计 + 对照协议，已实现）→ 报告层（调研报告，已实现）。

诚实边界。 检索、筛选、抽取、验证、评估与对照审计均由 agent/ 代码自动执行；认知层（第 4 层：Research Gap 识别、候选假设生成、路线优先级排序）在初赛阶段由开发期 AI 助手交互式完成并沉淀为 gaps.jsonl / hypotheses.jsonl / candidate_routes.jsonl，同时已基于 AgentScope 2.0 实现为可自主运行的 discover 阶段并完成小规模验证（见 §4.4.5）。复赛将把该**自主发现循环**作为认知层主运行方式：系统自主读取知识库 → 生成并筛选 Gap → 触发补充检索 → 生成假设 → 生成路线 → 撰写报告，循环至收敛条件，全部落 JSONL、可断点续跑、可审计——届时"自主阅读—形成判断—调用工具验证—沉淀结论"闭环由可运行代码完整承担。

三、发现信号与参照

3.1 什么算发现

- **正向发现：**一组"各步骤均有文献支撑、但从未被联合报道"的掺杂 × 工艺组合（例如某种卤素混配 + 掺杂 + 低温退火的组合）；
- **异常 / 反例：**发现某"公认最优条件"在不同文献中系统性矛盾（如卤素比例对电导率的影响结论相反），即现有共识存在测量/样本层面的偏差；
- **稳定负结果：**某被广泛引用的工艺条件在统计上并无显著优势，值得实验团队谨慎对待；
- **问题修正：**检索发现本切片已被新综述覆盖时，收窄或迁移到相邻体系（如从 $\text{Li}_6\text{PS}_5\text{Cl}$ 转向富卤素 $\text{Li}_{6+x}\text{PS}_{5-x}\text{Cl}_{1+x}$ 或氧化物-硫化物复合）。

3.2 平凡解 / 随机 / 无干预

参照系	定义	与 Agent 结果比较的指标
无干预	仅引用最高被引的标准工艺（纯 $\text{Li}_6\text{PS}_5\text{Cl}$ 球磨 + 550°C 退火）	证据链完整度、路线新颖性
随机	随机组合掺杂元素与工艺参数，不带文献支撑	可行性通过率、矛盾命中数
纯 LLM	不检索文献，直接让 LLM 生成合成路线	证据链完整度、可回溯性

超过参照的判据：Agent 产出的候选路线中存在 ≥ 1 条“**证据链完整 + 未被已有综述覆盖 + 可行性检查通过**”的路线，且其性能期望不劣于标准工艺（同一评价口径下）。

3.3 最低成功与失败标准

最低成功门槛：

- 结构化记录 ≥ 30 条；
- 产出 ≥ 5 个带证据链的 Research Gap；
- 产出 ≥ 1 条新颖合成路线假设（证据链完整、可行性检查通过）。

明确失败判定：

- Sciverse API 不可用 / 检索返回空；
- 抽取质量差（结构化记录 < 10 条且不可用）；
- 全部候选路线被证据链或可行性检查否定。

更新机制：失败发生时——先降低切片粒度（从复合体系聚焦单一体系）→ 切换/补充文献源（Sci-Base、MinerU）→ 调整检索词与抽取规则 → 仍无效则修正问题边界（迁移主题）。

四、最小验证计划

4.1 一次试跑怎么做

试跑目标：验证"检索 → 筛选 → 抽取 → Gap 识别 → 路线生成 → 证据回溯"最小闭环可跑通，并产出至少 1 条带证据链的候选路线。

输入：Sciverse API key、检索词表（argyrodite / Li₆PS₅Cl / 卤素混配 / 掺杂 / 合成工艺 / 空气稳定性等）、领域约束规则。

步骤：

1. 检索 100–200 篇核心文献；
2. 筛选至 50 篇（按相关性、证据等级）；
3. 抽取 30 条"配方-工艺-性能"结构化记录；
4. Research Gap 识别（含矛盾检测）；
5. 生成 10 条候选合成路线假设；
6. 逐一证据回溯 + Materials Project / 热力学代理检查；
7. 选出 top 3，写入合成方案。

输出：调研报告草案 + 候选路线清单 + 证据链 JSON。

需要记录的关键证据：检索日志（查询、时间戳、命中数）、抽取记录、Gap 清单、每条候选路线的证据链。

4.2 主要风险与失败路径

风险	失败后的定位与处理
API 注册/可用性受阻	备用 Sci-Base / MinerU；先跑通流程再换主数据源
全文覆盖不足（只有摘要）	摘要级信息起步，必要时用 MinerU 深度解析正文
LLM 幻觉（编造文献或性能数据）	强制证据链校验：每条引用可回溯，无 ID 即丢弃
文献数据不可比	只做"方向性"比较，标注测量条件，不做伪精确

风险	失败后的定位与处理
领域术语误读	建立词典/本体约束（F-43m、NIS、NPS、H ₂ S 等）
时间风险	初赛 8.16 截止，按倒排工期推进

4.3 复现与开源计划

- **数据来源：**Sciverse API 检索记录（可审计证据链）、Sci-Base（Hugging Face）、Materials Project API；
- **依赖工具：**数据/审计层运行时为本项目自研 Python 流水线（agent/，纯标准库，零第三方依赖）；认知层编排（discover 阶段）唯一第三方依赖为 AgentScope 2.0（Apache-2.0，见 requirements.txt）。外部服务为 Sciverse（REST 检索/全文）、LLM（Anthropic 兼容端点，DeepSeek）与 Materials Project（REST 背景查询）；存储为 JSON/JSONL 追加式知识库。Claude 为开发期辅助工具，不属于运行时依赖；
- **运行流程：**config（检索词/约束/预算）→ pipeline（检索-筛选-抽取-Gap-生成-验证）→ 日志，一键可复跑；
- **复现方式：**固定随机种子、保留检索查询与时间戳、输出结构化 JSON，提供 README 与环境配置；
- **开源计划：**GitHub 仓库（MIT 许可），代码、数据管线、日志脱敏后开源；商业 API（Sciverse、LLM）使用环节、费用假设、可替代性与对可复现性的影响在提交材料中披露。

四补充、阶段性实测结果与扩充审计 (2026-08-02)

§4.1 所述最小闭环已跑通；此后系统进行了全文扩充、结构化抽取与原文审计。本节区分两个阶段：阶段 I 证明流水线最小闭环可运行；阶段 II 检验其在更大语料上的可追溯性、对反例的响应能力与路线边界。候选路线均是待证伪假设，不是湿实验结果。

4.4.1 阶段 I：最小闭环验证

步骤	阶段 I 计划	阶段 I 实测	状态
检索核心文献	100–200 篇	158 篇去重（16 组查询）	✓
筛选	50 篇	50 篇	✓
结构化抽取	≥30 条	49 条	✓
Gap 识别	≥5 个	9 个	✓
候选假设	10 条	hyp_001 – hyp_010	✓
MP 交叉背景查询	完成	baseline 与候选组成 thermo/core 查询	✓
路线选择	top 3	route_A/B/C 初始候选	✓

阶段 I 达到 §3.3 的最低门槛，证明“检索 → 筛选 → 抽取 → Gap → 路线 → 证据回溯”闭环可运行。

4.4.2 阶段 II：全文扩充、质量审计与假设收缩

图 1 从最小闭环到可审计证据语料
阶段 I 验证流程可运行；阶段 II 扩充形成可回溯的知识层（数据快照：2026-08-02）




图 1 从最小闭环到可审计证据语料。阶段 I 最小闭环已跑通；阶段 II 将全文语料扩充至 346 篇，形成 346 条可回溯结构化记录，全部全文已完成结构化，无待重试项。来源： data/99_logs/evaluation_20260802.json 。

指标	阶段 II 实测
已保存全文	346 篇
成功结构化记录	346 条唯一 doc_id -> record_id
可回溯至本地全文的记录	346/346 (100%)
核心 argyrodite 记录	88/346 (25.4%)
Research Gap	11 个
候选假设	12 条
候选路线库	4 条 (含 route_D) + 对照协议文献 Agent 臂扩展至 12 条
原文审计样本	10 条; 9 条直接核心证据、1 条仅限理论比较
待重试全文	0 篇 (全部完成结构化)

关键字段覆盖率为：体系 81.2%、合成路线 58.1%、电导率 44.8%、前驱体 41.0%、球磨条件 25.1%、退火温度 21.1%、测量温度 26.3%。这既证明了抽取规模，也说明工艺和测量元数据仍常在原文中缺失，不能把跨论文数值直接排序。




图 2 结构化知识层的字段覆盖率。 体系与结果字段覆盖较高，而球磨、退火、测量温度等关键工艺元数据缺失明显；因此跨论文电导率不能直接排序，路线优先级需同时约束组成、压实、热史与温度口径。来源：

data/99_logs/evaluation_20260802.json 。

阶段 II 的关键科学信号是“反证与假设收缩”：扩充语料证明 Br-rich 无序/淬冷（rec_111）、Li6PS5Cl 氧硫化物保护层（rec_250）、富 Cl/Br 组成扫描（rec_287）与多价阳离子晶界调控（rec_310）已有先例。因此，系统新增 gap_011 以限制早期过宽的“未报道”表述，而非继续放大新颖性。这证明 Agent 能利用新证据修正自身路线空间。

图 4 扩充语料触发的反证与假设收缩
四例先例证据使早期“未报道”表述收敛为可逐项检验的条件化假设 (gap_011)

审计记录	早期过宽表述	扩充语料中的反证 / 限制	更新后的可证伪边界
rec_111 Do not claim Br-rich disordering or cooling control is unexplored. Attribute any numerical result to the exact composition and cooling treatment.	Br-rich 无序 / 淬冷控制可作为强新颖性主张	已有 Br-rich 组成与淬冷/慢冷对照	仅检验精确组成和变量组合；不再称该概念未报道
rec_250 Do not claim that sulfide/oxide-like protective-shell concepts are absent. This is oxysulfide, not proof for every proposed oxide shell.	Li6PS5Cl 保护层作为泛化新概念	约 50 nm 氧硫化物保护层已有先例	限定为具体表面化学；不将“保护层”泛称无先例
rec_287 Do not claim the full Cl/Br-rich composition space is unexplored; use as an optimization benchmark requiring direct source confirmation for numeric values.	富 Cl/Br 组成空间整体未被探索	$x=0.4 / 0.8 / 1.2$ 组成扫描已有报道	不再宣称全空间未探索；以直接复核作为优化基准
rec_310 Do not present these high-temperature values as room-temperature gains; the source indicates only slight room-temperature improvement.	多价离子晶界调控可直接写为室温增益	12.9 mS/cm (70 C) 和 13 mS/cm (50 C)	高值必须带温度标签；室温结论单独核查
Agent 的产出不只包含候选生成：当新增原文证据削弱主张时，系统保留反证并收缩假设空间。			

图 4 扩充语料触发的反证与假设收缩。 四条先例证据（rec_111 / rec_250 / rec_287 / rec_310）使早期过宽的“未报道”表述收敛为可逐项检验的条件化假设；Agent 保留反证并收缩假设空间，而非放大新颖性。来源：

data/02_knowledge/extraction_quality_audit_20260802.json 。

完整统计和 10 条原文核查见 data/99_logs/evaluation_20260802.json 与 data/02_knowledge/extraction_quality_audit_20260802.json 。

4.4.3 路线 C 输出：从初始候选到可证伪优先级

route_A/B/C 保留为阶段 I 的初始候选，用于展示从文献组合生成假设的能力；扩充后它们均需以更精确的组成、工艺与先例检索限定新颖性，不能被表述为已实现的性能优化。

当前最高优先级是新增的 route_D：Li6PS5Cl 基线致密化与可比性验证路线：

1. 以 Li₂S/P₂S₅/LiCl 制备 Li₆PS₅Cl 基线；
2. 在 550°C 下比较压片烧结 2/4/6/8/10 h，并保留粉末烧结对照；
3. 每个样品同时记录压实压力、相对密度、几何、XRD 与室温/升温 EIS；
4. 将升温电导率与室温数据严格分开报告。

该路线直接来自 rec_107（压片烧结 4 h：6.11 mS/cm）和 rec_217（25°C：1.30×10⁻³ S/cm；60°C：1.05×10⁻² S/cm）。其创新点是建立工艺可比性基线，不预设性能提升；若不能重现文献趋势，同样构成有意义的负结果。第二优先级为 hyp_012：以同一前驱体对 Li_{5.5}PS_{4.5}Cl_{1.5} 比较 350°C 与 450°C 真空退火，依据 rec_230 联合记录相、密度、Ea 和室温 EIS。

图 5 route_D: Li₆PS₅Cl 致密化与可比性 DOE

基线复现与测量口径控制路线；不预设电导率提升




图 5 route_D: Li₆PS₅Cl 致密化与可比性 DOE。待验证的实验设计而非已完成湿实验；基线复现 + 550°C 压片 2/4/6/8/10 h 时间序列 + 粉末对照 + 统一表征口径，不预设性能提升。来源：

data/04_routes/candidate_routes.jsonl（route_D）、rec_107、rec_217。

4.4.4 MP 交叉验证的正确边界

Li₆PS₅Cl/Br/I 的 MP baseline 条目为亚稳相背景；新增的 Li₆PS₅F_{0.3}Cl_{0.7}、Li₆PS₅Cl_{0.75}Br_{0.25} 和 Li_{5.5}PS_{4.5}Cl_{1.5} 查询均无

thermo/core 条目。无条目仅表示数据库覆盖缺口，不能证明材料稳定性、新颖性或合成可行性；MP 也不替代文献追溯、相分析与实验验证。

4.4.5 可复现评估与复赛计划

当前可复跑基线。 本项目已实现确定性的本地证据质量评估：


```
python -m agent.run --stage evaluate
```

该阶段只读取已冻结的本地 JSON/JSONL，不调用网络或 LLM；以 data/01_literature/ 中的全文 JSON、data/02_knowledge/ 中的 records.jsonl、Gap/假设及原文审计、data/03_cross_validate/ 的 MP 快照、data/04_routes/ 的路线库和 data/99_logs/ 的过程日志为输入。它检查唯一记录数、关键字段覆盖、doc_id -> record_id -> 原始全文 JSON 的可回溯性、审计样本分类和待处理全文数。因此，该命令是当前已执行的**数据质量与证据链基线**，不是湿实验结果，也不是模型间性能榜。

复赛工程化架构。 复赛代码采用两层架构：数据/审计层由本项目自研 Python 流水线（agent/，纯标准库，零第三方依赖）承担，run.py 调度“检索—筛选—全文—抽取—验证—评估—路线—对照审计”，Sciverse REST 负责检索与 doc_id /片段获取，结构化抽取器把配方、前驱体、球磨、退火、性能和证据等级写入追加式知识层，Gap/路线模块只消费已存档记录，Materials Project REST 仅作为结构/热力学背景检查；认知层由 discover 阶段承担，基于 **AgentScope 2.0**（Apache-2.0，唯一第三方运行时依赖）把此前开发期由 AI 助手交互完成的 Gap 识别、假设生成与路线策划代码化为**自主发现循环**：系统自主读取知识库 → 生成并筛选 Gap → 触发补充检索 → 生成假设 → 生成路线 → 撰写报告，循环至收敛，全部落 JSONL、可断点续跑、可审计（推理事件流落 discover_log.jsonl）。该循环已于 2026-08-03 在 346 条语料上完成最小验证：自主产出带证据锚点的 gap_012 / hyp_013 / route_E（id 续编），且最小循环路径不改动既有语料、--stage evaluate 输出与基线逐字节一致。每次路线生成均保存路线步骤、组成和工艺参数、引用的 record_id / doc_id、原文证据片段、温度标签、化学约束检查、先例/重复命中，以及遇到反证后的否决或假设收缩理由，形成可逐条审计的路线卡。

图 3 自研文献科学发现流水线的可审计架构

编排层 = AgentScope 2.0 (discover 循环) ; 数据/审计层 = 自研 Python 流水线; 模块可独立重跑



边界: Materials Project 仅提供结构/热力学背景; 无条目表示数据库覆盖缺口, 不验证合成路线、稳定性或新颖性。

图 3 自研文献科学发现流水线的可审计架构。编排层 (AgentScope 2.0, discover 循环) 只负责自主决策与工具调用; 数据/审计层为自研标准库流水线, 检索、筛选、抽取、Gap/路线与回溯验证均保留中间产物; doc_id -> record_id -> 原始全文 JSON 为最小证据锚点。MP 仅作结构/热力学背景, 无条目表示数据库覆盖缺口, 不验证合成路线、稳定性或新颖性。

统一对照协议。 在同一冻结语料、同一 schema 和同一审计规则下, 复赛将实际运行四个生成臂:

1. **固定工艺基线:** 采用文献标准 Li6PS5Cl 流程; 只在组成、压实、热史和测量温度齐全时参与比较;
2. **纯 LLM 基线:** 关闭检索与证据注入, 直接生成路线, 再由相同本地语料进行事后审计;
3. **随机拼接基线:** 使用固定随机种子, 从已记录的组成/工艺字段中随机组装候选, 并执行相同化学与证据检查;
4. **文献 Agent:** 检索、结构化抽取、Gap/先例过滤和证据回溯后生成路线, 并允许反证触发假设收缩。

四组输出均以路线步骤为最小审计单元, 报告以下指标: **有证据步骤比例** (步骤具备有效原文锚点的比例)、**无证据断言率** (找不到 record_id / doc_id 支持的工艺或性能断言比例)、**测量温度标签合规率** (室温、升温、理论和引用他文数据是否被正确区分)、**组成/工艺约束通过率**、**先例/重复命中率**, 以及**反证后假设收缩率**。协议定义与本地证据质量基线已完成; 四组对照的实测结果与解读见 §4.4.6 (2026-08-03)。

冻结与复现实务。 每次正式运行将固化语料快照日期、查询词表和筛选配置版本、抽取 JSON schema、提示词/模型版本、随机种子、每阶段时间戳、API 调用数与预算；记录采用追加式保存，成功 doc_id 不重复抽取。密钥只从环境变量读取，不进入代码、日志或提交包；Sciverse、LLM 与 MP 的权限、费用、替代实现及服务波动影响将一并披露。即使外部服务不可用，`--stage evaluate` 仍可对冻结产物进行离线复核。

复赛执行顺序。 首先重跑本地质量评估并锁定输入快照；随后生成并审计四组路线，对代表性路线逐篇回查原文；再以 MP 做非决定性的背景查询，筛出证据充分而未被反证否决的候选。最终进入湿实验的路线才进行 XRD、相对密度、样品几何、室温 EIS 与升温 EIS 验证，且室温和升温结果分别报告。湿实验数据及任何模型对照分数均属于复赛后续结果，不能由当前文献证据替代。

4.4.6 统一对照协议实测结果（2026-08-03）

同一冻结语料（2026-08-02 快照）、同一 route schema、同一审计规则下，四个生成臂已实际运行并完成确定性审计。对照输出是**文献证据审计结果**，不是湿实验性能，也不是模型间排行榜。

四臂定义与冻结产物：① 固定工艺基线＝文献标准 Li6PS5Cl 流程（route_D，组成/压实/热史/测量温度齐全）；② 纯 LLM 基线＝无检索、无证据注入，直接调 LLM 生成路线；③ 随机拼接基线＝固定随机种子，从已记录组成/工艺字段随机拼装；④ 文献 Agent＝检索＋抽取＋Gap＋证据回溯＋反证收缩。冻结路线存于 `data/05_comparator/routes_{arm}.jsonl`。

复现命令：


```
python -m agent.run --stage gen --arm all --seed 42 # 生成/冻结各臂路
python -m agent.run --stage compare # 确定性审计（无
```

六项指标 × 四臂实测（语料快照 2026-08-02；审计日 2026-08-03；样本量：固定 1、纯 LLM 10、随机 20、文献 Agent 12）：

生成臂	路线数	有证据步骤	无证据断言率	温度标签合规	约束通过率	先例命中	反证收缩率
固定工艺基线	1	100%	0%	100%	100%	50%	0%
纯LLM基线	10	0%	100%	100%	100%	60%	0%
随机拼接基线	20	0%	100%	52%	84%	50%	0%
文献Agent	12	100%	0%	83%	98%	15%	17%

图 6 四组生成臂的确定性对照审计

同一冻结语料 (2026-08-02) 与同一审计规则下，先证断言率越低越好 (审计日 2026-08-03)



解读：文献 Agent 与固定基线全部步骤可回溯原文锚点，反证收缩率仅文献 Agent 具备 (hyp_007/hyp_009 经 gap_011 收窄)。纯 LLM 先例命中高但无可回溯锚点；随机拼接复用已记录字段，证据与化学/先例合理性均低于文献 Agent。

图 6 四组生成臂的确定性对照审计。有证据步骤比例与无证据断言率衡量证据链可回溯性；纯 LLM 与随机基线按协议不注入证据。先例命中衡量步骤条件与语料记录值的重合，不等于证据可回溯。反证收缩率仅文献 Agent 具备。来源：data/99_logs/comparator_20260803.json。

解读与边界：

1. 可回溯性是检索 + 抽取 + 证据回溯带来的：文献 Agent 与固定基线的全部步骤都有可回溯原文锚点（100% 有证据步骤、0% 无证据断言）；纯 LLM 与随机基线按协议无锚点（0%/100%）。先例命中不等于证据可回溯：先例命中衡量步骤条件与语料记录值（温度/时间/工艺词）的重

合，本轮纯 LLM 60% > 随机 50% > 文献 Agent 15%——文献 Agent 派生路线以支持记录为证据锚点（supp 100%），但步骤条件多为通用描述，不与具体记录值重合，故先例命中反而低。

2. **审计规则能识别文献 Agent 自身的表述缺陷**：温度标签合规率仍精确标出阶段 I 初始路线 route_A/C 的电导率断言缺少测量温度标签（temp 0%），route_D/B 通过；8 条假设派生路线大多不声称新的电导率数值（100% 空过），若声称则按同一规则标记，文献 Agent 总 temp 83%。这正是 route_D 可比性口径改进要解决的问题，也证明审计不是只放大 Agent 的优点。
3. **约束与反证**：固定基线、纯 LLM 与文献 Agent 约束通过率 100%/100%/98%——文献 Agent 仅 hyp_007 氧化物壳层路线因目标组成只给定氧化物式（Li₄SiO₄，无 P/S）被标记，说明组成不完整给定会被约束审计捕获；随机 84%（池中混入无 Li-P-S 组成）。反证收缩率仅文献 Agent 具备（hyp_007 / hyp_009 经 gap_011 边界更新收窄，17%）。
4. **样本量**：固定 1、纯 LLM 10、随机 20、文献 Agent 12。固定基线按参与规则只有组成/压实/热史/测量温度齐全的 route_D 合格，因此维持 1 条；采样臂与文献 Agent 臂扩大样本以稳定均值。对照分数是对路线证据链与化学/先例合理性的审计，不构成性能优排行，也不代表湿实验性能。

4.4.7 阶段 III/IV 扩充：778 语料收官与自主发现规模化（2026-08-04）

本节为初赛方案追加更新（历史 §4.4.x 内容保留，口径以本节为准）。阶段 I-II 的 346 语料基线在此扩充至 778 篇全文，全部完成结构化抽取与确定性审计；discover 循环完成全量规模化并自主产出新路线。

语料扩充（任务 A 收官）

- 检索三轮扩充（v2/v3/v4 查询词表，共 ~250 条查询），Sciverse 累计调用 1062 次，hit_catalog 3562 条；语料自 346 → **778 篇全文**（+432），结构化记录 **778 条**（remaining 0，100% 可回溯至原文）。
- 核心 argyrodite 记录 **259/778（33.3%）**，保持筛选口径纪律（强词 ≥1 或弱词 ≥2），不放宽以维持核心占比。
- **语料上限结论**：当前严格筛选口径下理论上限约 785（hit_catalog 中能过筛的已基本入库），瓶颈在筛选规则而非检索量——validate /

evaluate / compare 全部通过，语料扩充收官。

- API 预算：Sciverse 1062 / DeepSeek 663 / Materials Project 10 (data/99_logs/budget.json)。

知识层与自主发现（任务 I）

层	数量	说明
Research Gap	19 (gap_001-019)	gap_012-019 为 discover 自主产出
候选假设	20 (hyp_001-020)	hyp_013-020 为 discover 自主产出
候选路线	12 (route_A-L)	route_E-L 为 discover 循环自主产出 (Ca/Y 共掺、Se 取代、O 取代、溶液法、ALD 包覆、I 基取代、Sb 基高熵、热压)
逆向合成	12 (retro_001-012)	LLM 推理 + 文献锚点，无效锚点剔除 0
DOE 协议	5 张表 (route_A-E)	experimental_DOE_protocols.md ，~37 样品覆盖核心假设
逐步骤推理链	route_D/A/C/E 等	reasoning_chains.md ，前驱体/温度/顺序选择依据

discover 全量规模化（778 语料 5 轮）：新增 5 gap + 5 hyp + route_H-L， --stage audit 判定 PASS，推理事件流存 discover_log.jsonl ；确定性审计（evaluate/compare/audit）零网络零 LLM，逐字节可复现。

统一对照协议实测（778 快照，审计日 2026-08-04）

生成臂	路线数	有证据步骤	无证据断言率	温度标签合规	约束通过率	先例命中	反证收缩率
固定工艺基线	1	100%	0%	100%	100%	50%	0%

生成臂	路线数	有证据步骤	无证据断言率	温度标签合规	约束通过率	先例命中	反证收缩率
纯 LLM 基线	10	0%	100%	100%	100%	63%	0%
随机拼接基线	20	0%	100%	52%	84%	50%	0%
文献 Agent	12	100%	0%	83%	98%	17%	10%

结论：文献 Agent（本系统）是唯一做到 100% 有证据步骤、0% 无证据断言且具备反证收缩能力的臂；纯 LLM/随机基线虽偶有"先例命中"，但无一条步骤可回溯——证明证据链注入的必要性。指标口径与边界同 §4.4.6 第 4 点。

交付物

- 复赛三件套：复赛实验报告_方向三_固态电解质.md 、 科学意义说明_方向三_固态电解质.md 、 DEPENDENCIES_DISCLOSURE.md 。
- 代码仓库规范化：README.md / LICENSE / REPRODUCIBILITY.md / DEPENDENCIES_DISCLOSURE.md 。
- 静态 Demo 已上线：<https://lc-di-yan.github.io/SigmaMiner/>（线上 Selenium 回归通过）。
- 本初赛提交包已同步至 778 快照（data/ 、 agent/ 、 queries/ v1-v4、清单）。

附录 · 优化与修复增补说明（摘要）

本附录追加于《初赛方案.pdf》正文之后，记录 2026-08-04 定稿至 2026-08-15 期间完成的证据链修复与功能补齐，不修改正文任何一页。完整版见同目录《优化与修复增补说明.md》。

一、证据链正确性修复（P0）

- 检出：detect_docid_mismatch.py 抓到 56 处 evidence_doc_ids 与 records 真实 doc_id 不一致，含 discover 循环对 doc_id 的复用/伪造，以及早期 12 位短哈希截断；修复前 audit 因不检查该字段而误判 PASS。
- 根因：read_knowledge 未暴露 doc_id → LLM 只能臆造；write_gap 不回填不校验；audit 不核对 doc_id 配对。
- 修复：fix_docid.py 按 record_id 反查回填 17 个 gap 的真实 doc_id（备份 gaps.jsonl.pre_fixdocid）；write_gap 改为落盘前按 record_id 回填；audit 新增 record_id↔doc_id 配对一致性校验。
- 验收：mismatch = 0；--stage audit 判定 PASS（gaps 19/19、hypotheses 20/20、routes 12/12）。

二、口径与可复现对齐（P1）

- evaluate 输出按快照日期命名（evaluation_{snapshot}.json）且已存在则拒绝覆盖；comparator 冻结路线拒绝覆盖，audited_corpus 动态指向最新评估快照。
- 核心 argyrodite 占比统一为机器正则口径 $133/778 = 17.1\%$ （取代早期不一致的 25.4%/33.3%）。
- 调研报告补 § 11（778 增补）；清单主文件引用改为初赛方案.pdf。

三、功能补齐（P2，均为纯标准库确定性实现）

- 实体规范化与单位统一（--stage normalize）：283 种 conductivity 写法归一为 S/cm，可归一单值 188 条（中位 1 mS/cm），范围/多值/描述如实标记。
- 跨文献矛盾检测（--stage contradictions）：同一归一体系内电导率差 ≥ 10 倍，85 条候选矛盾对、17 体系（Li6PS5Cl 跨文献 2-3 个数量级），带测量温度标签可复核。
- 报告生成（--stage report）：从 JSONL 无 LLM 确定性渲染九节调研报告（调研报告_auto_20260804.md），证明报告非自由生成。
- 检索质量自评估（--stage retrieval-eval）：317 query / 9350 命中，规则弱标注下 $P_{strong@10}=0.658$ 、 $recall_{rel@10}=0.440$ 、 $nDCG@10=0.875$ 。

四、验收汇总（可复跑）

命令	输出	结果
python detect_docid_mismatch.py	mismatch 总数	0
python -m agent.run --stage audit	audit_*.json	PASS (19/20/12)
python -m agent.run --stage normalize	normalized_conductivity.jsonl	exact 188
python -m agent.run --stage contradictions	contradictions.jsonl	85 对 / 17 体系
python -m agent.run --stage report --snapshot 20260804	调研报告_auto_20260804.md	九节可回溯
python -m agent.run --stage retrieval-eval	retrieval_eval_*.json	nDCG@10=0.875

五、诚实披露与边界

修复前曾存在 56 处 evidence_doc_ids 不一致，本附录不掩盖，检测脚本、修复脚本与备份均留痕，可复现复核；所有新增功能零运行时依赖、无网络、无 LLM；候选 Gap/假设/路线均为待证伪假设，矛盾检测为未对齐测量温度的初筛。